

Datos | Vivos

— datosvivos.co

El panorama de los datos abiertos de Colombia.



Concurso Datos al Ecosistema 2026: IA para Colombia — MinTIC

Equipo 93 · Reto de Innovación y Tecnología (Reto 7, id 102) · Nivel Avanzado · GIT TIC — ANI

Nadie tiene el panorama



LA ENTIDAD

no sabe cuántos datasets tiene
ni cuántos están al día



EL SECTOR

sin vista consolidada de sus
entidades adscritas: cero
control



EL MINTIC

los portales federados viven
separados — no hay agregado



EL CIUDADANO

necesita APIs y SQL
para una simple cifra

El dato público existe — pero nadie puede verlo completo ni usarlo sin conocimientos técnicos.



“Si no conocemos, no podemos medir.

Y si no medimos, no podemos mejorar.”

El dato bien gobernado es infraestructura — tan estratégica como las vías.

Tres niveles, una sola fuente de verdad



De lo general a lo puntual: panorama → detalle → dato exacto. Cada nivel dirige al siguiente.

El panorama, en vivo — se actualiza solo cada día



EL HALLAZGO QUE NADIE VEÍA — fresca contra la promesa de cada entidad:



El 71 % del catálogo incumple la frecuencia que su PROPIA entidad declaró — invisible hasta ahora.

Cifras del corte 2026-07-12, verificables en vivo: datosvivos.co/api/v1/stats/panorama

El control de gestión, en dos clics

Semáforo por entidad

verde $\leq$ frecuencia declarada · amarillo $\leq 2\times$ · rojo $> 2\times$. El % de cumplimiento listo para gestión.

Uso real

descargas, vistas e interés reciente: qué datasets le importan a la ciudadanía.

Territorio DIVIPOLA

mapa con drill departamento $\rightarrow$ municipio (~89 % de cobertura inferida con IA).

Filtros del decisor

sector · entidad · acceso · calidad (Ley 1712) · territorio.

La IA está DETRÁS del tablero: depuración, consolidación y casos de calidad de los datos se definieron con IA.

“¿Cuántos colegios públicos hay en Boyacá?”



0 **100 %** **Voz**

cifras inventadas — si no se puede verificar, se rehúsa respuestas con fuente citada y consulta visible entrada hablada y respuesta narrada (Ley 1618)

La IA razona, el motor verifica

IA generativa + arquitectura híbrida — pertinente, aplicable e interpretable. Nunca superficial.

EN LOS TABLEROS

- Consolidación de 6 portales heterogéneos
- Clasificación automática de calidad (Ley 1712)
- Curación de columnas con LLM + heurísticas
- Inferencia territorial DIVIPOLA (~89 %)
- Guardas anti-basura en la ingesta

EN EL BUSCADOR

- NL2SQL verificado en 3 capas
- Embeddings e5 + ChromaDB (retrieval semántico)
- 6 tipos de respuesta (conteo, suma, mapa...)
- Narrativa anti-alucinación (censura números ajenos)
- MCP server para cualquier agente de IA

CRISP-ML(Q), adaptado a un catálogo vivo



La adaptación central

en vez de entrenar-y-congelar un modelo, CADA consulta pasa por generación (LLM) → verificación (código) → ejecución.

Evaluación doble

golden sets técnicos versionados + ciclo ciudadano: 50 preguntas reales con respuesta esperada pre-registrada, corridas por ciclos.

Nivel Avanzado, con la letra del pliego

Agentes de IA

consulta y procesa datos abiertos automáticamente para responder a la ciudadanía.

IA generativa conversacional

buscador NL2SQL / Text-to-SQL generativo verificado.

Arquitectura híbrida

LLM razona + motor determinista verifica + embeddings neuronales.

Grandes volúmenes

25.226 datasets · 6 fuentes · 3 protocolos (el intermedio pide 3-10 conjuntos).

Estructurados y no estructurados

metadata + texto libre con embeddings; 29 variables curadas (el intermedio pide 10-20).

Despliegue funcional

actualización diaria automática y EN PRODUCCIÓN: datosvivos.co.

De la entidad al país



Escala: agregar un portal es configuración — el patrón sirve a cualquier país con Socrata, CKAN o DCAT.

EQUIPO GIT TIC — AGENCIA NACIONAL DE INFRAESTRUCTURA (ANI)

Hernán Darío Gutiérrez Casas — líder estratégico · Ileana Andrea Navarro Castrillón — líder de equipo y comunicaciones · Jhonatan Sneider Rico Pinto — líder técnico y de datos

LO QUE YA CORRE · JULIO 2026

~1.5 s

motor de lenguaje
en la API de Claude

10.279

datasets en bodega local
→ respuesta en milisegundos

100 %

catalogación
temática

50

preguntas ciudadanas
→ mejoras estructurales

Lo que sigue: filtros de año/municipio dentro del dataset · respuestas compuestas (KPI + tendencia + per cápita).

datosvivos.co

El panorama de los datos abiertos de Colombia. En vivo, verificable, para decidir.

Arquitectura de 3 capas (fiel al plan de inscripción)

PRESENTACIÓN

Next.js (panorama + buscador SSE) · Power BI publish-to-web sobre CSVs públicos de la API

MOTOR

FastAPI + PostgreSQL (catálogo curado, vistas _decisor) · ChromaDB (retrieval semántico en ambos caminos) · DuckDB (bodega Parquet 10.279 datasets + CSVs federados) · LLM intercambiable (prod: API de Claude)

MCP / FUENTES

MCP server sobre las APIs de datos.gov.co (Discovery · SODA · Metadata) + cosecha CKAN/DCAT — search · metadata · query · cross

Despliegue: Docker Compose reproducible · túnel seguro de salida · cron diario (ETL + regla de cola de la bodega).

Motor NL2SQL: generar no basta — hay que verificar



Preferimos no responder a responder mal

ciclo de reparación acotado; si la verificación persiste en fallar, refusal explícito.

Respaldo determinista

plantillas por tipo (conteo · suma · comparación · ranking · tendencia · mapa) como camino estructurado con chips.

Modelo de datos: una vista curada como fuente única

datasets (42 columnas)

una fila por dataset del catálogo integrado; upsert idempotente por dataset_id (auditado: 0 duplicados de clave).

v_dataset_status_decisor (29 variables)

identidad, semáforo de frescura, uso, acceso, territorio DIVIPOLA y calidad.

v_entity_summary_decisor

agregado por entidad con pct_verdes: el indicador de cumplimiento listo para gestión.

dataset_snapshots (bodega)

manifest de los 10.279 Parquet locales: frescura del snapshot decide bodega-vs-vivo; orígenes muertos (403) penalizan el ranking.

Una sola fuente de verdad

panorama web, tablero Power BI y CSVs públicos leen LA MISMA vista — imposible que se desalineen.

Calidad de datos: medida, no declarada

Auditoría columna a columna

17/18 columnas al 100 % de fidelidad contra la fuente Socrata (reportes versionados en eval/reports/).

Clasificación continua

los reportes administrativos (Ley 1712) se separan de los datos temáticos automáticamente, en cada corrida del ETL.

Catalogación temática al 100 %

0 datasets útiles sin categoría; vocabulario consolidado a 26 canónicas, re-unificado cada noche.

Inferencia territorial

códigos DIVIPOLA asignados por IA con confianza registrada (~89 % de cobertura).

Guardas anti-basura

metadata de plantilla sin diligenciar ({{{...}}}) se limpia en TODOS los campos de la ingesta.

Evaluación y trazabilidad

Golden sets versionados

eval/golden_queries.yaml y golden_chips.yaml — corridas reproducibles (últimas: 18/18 y 38/38, 0 falsos verificados).

Ciclo ciudadano

50 preguntas reales con respuesta esperada PRE-registrada (eval/ciudadano/): los patrones detectados se vuelven mejoras estructurales, y el ciclo se repite.

36 archivos de pruebas

verificador SoQL, validador anti-alucinación, reparación, geo/DIVIPOLA, cosecha, MCP, rutas de API.

Decisiones documentadas

ADRs públicos (017-023): del principio 'la IA razona, el motor verifica' al pivote panorama-decisor.

Telemetría anónima

lo más consultado alimenta la mejora sin datos personales.

Soberanía, seguridad y cumplimiento

Infraestructura del Estado

el servicio corre en infraestructura pública; los datos consultados son públicos por definición.

Sin datos personales

cero registro, cero rastreadores; telemetría agregada y anónima.

Solo lectura

el motor no puede escribir en ninguna fuente; verificación de solo-lectura en la capa 2.

Repo abierto y auditable

código, documentación, pruebas y evaluación públicos — replicable con Docker (guía de validación para el jurado).

Accesibilidad

Ley 1618 de 2013 y WCAG 2.1 AA: voz, narración, contraste, escala tipográfica.