

Datos | Vivos

— el panorama de los datos abiertos de Colombia

Datos del Estado, en tus palabras.

Concurso Datos al Ecosistema 2026: IA para Colombia — MinTIC

Equipo 93 · Reto de Innovación y Tecnología (Reto 7, id 102) · Nivel Avanzado · GIT TIC — ANI

Nadie tiene el panorama

La entidad

no sabe cuántos datasets tiene publicados ni cuántos están actualizados — la respuesta exige revisar el portal dataset por dataset.

El gerente de sector

con N entidades adscritas no puede hacer control: no existe una vista consolidada de qué publica su sector ni con qué frescura.

El propio MinTIC

carece de panorama: los portales federados (Bogotá, Cali, Medellín, Valle, IGAC) viven separados, con estándares distintos.

El ciudadano

que quiere una cifra necesita saber de APIs, SQL o procesar archivos. El dato público existe, pero es inaccesible.

“Si no conocemos, no podemos medir.

Y si no medimos, no podemos mejorar.”

El dato bien gobernado es infraestructura — tan estratégica como las vías.

DatosVivos: tres niveles, una sola fuente de verdad

1 • INICIO

Panorama nacional — datosvivos.co

Cifras en vivo del ecosistema completo: cuántos datasets, quién publica, qué tan frescos, cómo se accede. Para decidir en segundos.

2 • DETALLE POR ENTIDAD

/tablero (Power BI)

El detalle explorable: filtros por sector, entidad, acceso y territorio. Para el control de gestión.

3 • BUSCAR

/buscar (lenguaje natural)

El ciudadano pregunta en sus palabras; el motor NL2SQL verificado responde con cifras de las filas reales, citando la fuente.

De lo general a lo puntual: panorama → detalle → dato exacto. Cada nivel dirige al siguiente.

El panorama, en vivo

25.192

datasets integrados

1.423

entidades publicadoras

6

portales consolidados

29

variables curadas por
dataset

71 %

del catálogo en ROJO

El hallazgo que nadie veía

el 71 % de los datasets está desactualizado frente a la frecuencia que su PROPIA entidad declaró. Solo el 9 % está al día.

Se actualiza solo, todos los días

ETL nocturno + cosecha semanal + clasificación automática. Ninguna cifra está quemada: el panorama nunca envejece.

Cifras que varían a diario

estos números son el corte del 2026-07-10 — verificables en vivo en datosvivos.co/api/v1/stats/panorama.

El control de gestión, por sector y entidad

Salud del catálogo

semáforo de frescura por entidad: verde $\leq$ frecuencia declarada · amarillo $\leq 2\times$ · rojo $> 2\times$. El % de cumplimiento por entidad, listo para gestión.

Uso

descargas, vistas e interés reciente: qué datasets importan a la ciudadanía.

Cobertura territorial

mapa DIVIPOLA con drill departamento $\rightarrow$ municipio.

Filtros del decisor

sector · entidad · tipo de acceso · calidad (Ley 1712) · territorio — la pregunta '¿cómo está MI sector?' se responde en dos clics.

IA detrás del tablero

la depuración, consolidación y definición de los casos de calidad de datos se hizo con IA: clasificación automática, curación de metadata, inferencia territorial.

“¿Cuántos colegios públicos hay en Boyacá?”

NL2SQL / Text-to-SQL

el ciudadano escribe en lenguaje natural; el motor genera la consulta SQL sobre el dataset correcto y la ejecuta contra los datos oficiales.

Cero cifras inventadas

verificación determinista ANTES de ejecutar + validación de cada número de la respuesta contra las filas reales. Si no se puede verificar, se rehúsa — nunca se estima.

Fuente citada, siempre

cada respuesta enlaza el dataset original y muestra la consulta generada (transparencia auditable).

Accesible por diseño

entrada por voz y respuesta narrada — Ley 1618 de 2013.

Un agente de IA para servicios públicos

IA generativa + arquitectura híbrida: modelos de lenguaje que razonan, motor determinista que verifica. Pertinente, aplicable e interpretable — nunca superficial.

EN LOS TABLEROS

- Depuración y consolidación de 6 portales heterogéneos
- Definición de casos de calidad: clasificación automática de reportes administrativos (Ley 1712)
- Curación de columnas y metadata (LLM + heurísticas)
- Inferencia territorial DIVIPOLA (~89 % de cobertura)
- Guardas anti-basura (metadata placeholder)

EN EL BUSCADOR

- NL2SQL generativo con verificación determinista de 3 capas (genera → verifica con código → ejecuta)
- Embeddings semánticos (multilingual-e5 + ChromaDB) para elegir el dataset correcto
- Clasificador de intención y mapeo a consultas estructuradas
- Narrativa anti-alucinación: todo número se valida contra las filas
- MCP server: las herramientas expuestas a cualquier agente de IA

CRISP-ML(Q), adaptado a un catálogo vivo

Entendimiento

el 'dato' es doble: la metadata de 25.192 datasets y las filas consultadas bajo demanda.

Preparación — donde la IA depura

ETL diario + cosecha CKAN/DCAT; calidad auditada columna a columna contra la fuente (17/18 al 100 %); clasificación y curación automáticas.

Modelado — generar y VERIFICAR

adaptación central: en vez de entrenar-y-congelar, cada consulta pasa por generación (LLM) → verificación (código) → ejecución.

Evaluación

golden sets versionados + 35 archivos de pruebas + el verificador embebido en producción.

Despliegue y monitoreo (la Q)

Docker reproducible; actualización diaria automática; el semáforo monitorea la deriva DEL CATÁLOGO, no del modelo.

Nivel Avanzado, con la letra del pliego

Agentes de IA para servicios públicos

el agente consulta y procesa datos abiertos de manera automática para responder solicitudes ciudadanas.

IA generativa y sistemas conversacionales

buscador conversacional basado en datos abiertos: NL2SQL / Text-to-SQL generativo verificado.

Modelos de lenguaje + arquitectura híbrida

el LLM razona, el motor determinista verifica (3 capas) — con embeddings neuronales de retrieval.

Integración de grandes volúmenes

25.192 datasets de 6 fuentes y 3 protocolos — muy por encima de los 3-10 conjuntos del nivel intermedio.

Datos estructurados y no estructurados

metadata estructurada + texto libre procesado con embeddings; 29 variables curadas por dataset (el intermedio pide 10-20).

Automatización, escalabilidad y despliegue funcional

actualización diaria automática y solución EN PRODUCCIÓN: datosvivos.co.

Lo que nadie más hace

Integra los portales federados

datos.gov.co + IGAC + Bogotá + Cali + Medellín + Valle en un catálogo comparable. Hoy, eso exige revisar sitio por sitio.

Se actualiza solo

panorama diario automático — no es un informe: es infraestructura viva.

Verificable de punta a punta

cada cifra con fuente citada; API pública para auditar los números del sitio; repo abierto y replicable.

Interoperable por estándar

MCP server: cualquier agente de IA puede consultar el catálogo colombiano.

Accesible e institucional

identidad gov.co, voz y narración (Ley 1618), sin registro y sin rastreadores.

De la entidad al país

Entidad

ve su inventario y su rezago en segundos → corrige.

Sector

control consolidado de las entidades adscritas → gestiona.

MinTIC

panorama nacional medible para las Hojas de Ruta de Datos Abiertos → política basada en evidencia.

Ciudadanía

el dato público deja de exigir conocimientos técnicos → apropiación.

Escala

agregar un portal es configuración; el patrón sirve a cualquier país Socrata/CKAN/DCAT.

EQUIPO GIT TIC – AGENCIA NACIONAL DE INFRAESTRUCTURA

Hernán Darío Gutiérrez Casas (líder estratégico) · Ileana Andrea Navarro Castrillón (líder de equipo y comunicaciones) · Jhonatan Sneider Rico Pinto (líder técnico y de datos)

Lo que sigue

- 1 · Cosecha y catalogación previa de datasets — casos de consulta verificados para una búsqueda aún más precisa (6.2 GB ya liberados para la bodega).
- 2 · Motor de lenguaje ya migrado a la API de Claude: interpretación en ~1.5 s (antes 31-45 s) con verificación determinista intacta.

datosvivos.co

El panorama de los datos abiertos de Colombia. En vivo, verificable, para decidir.

Arquitectura de 3 capas (fiel al plan inicial de inscripción)

Capa MCP

servidor MCP sobre las APIs Socrata de datos.gov.co (Discovery, SODA, Metadata) — search_datasets · get_metadata · query_data · cross_datasets.

Capa motor

FastAPI + PostgreSQL (catálogo curado, vistas _decisor) + ChromaDB (retrieval) + DuckDB (federados con CSV externo) + backend LLM conectable — producción: API de Claude (Haiku); opción local: Ollama.

Capa presentación

Next.js (panorama + buscador SSE) y Power BI (tablero publish-to-web sobre CSVs públicos de la API). Evolución documentada: Streamlit → Next.js (ADR-011).

Despliegue

Docker Compose con imagen reproducible, túnel seguro de salida, cron de actualización diaria.

Motor NL2SQL: generar no basta — hay que verificar

Capa 1 · Esquema real

el LLM genera viendo SOLO columnas curadas reales del dataset (tipos semánticos: dimensión/métrica/fecha/geo). No puede alucinar columnas.

Capa 2 · Verificación estática

código (no otro LLM) valida columnas, funciones permitidas, filtro territorial y solo-lectura ANTES de ejecutar.

Capa 3 · Validación del resultado

toda cifra de la narrativa se contrasta contra la lista calculada de las filas; un número ajeno censura la oración.

Reparación y refusal

si la verificación falla: ciclo de reparación acotado; si persiste, la respuesta se niega. Preferimos no responder a responder mal.

Respaldo determinista

plantillas SoQL por tipo de pregunta (conteo/comparación/ranking/tendencia/mapa) como camino estructurado con chips.

Modelo de datos: una vista curada como fuente única

datasets (42 columnas)

una fila por dataset del catálogo integrado; upsert idempotente por dataset_id (auditado: 0 duplicados de clave).

v_dataset_status_decisor (29 variables)

la vista del decisor: identidad, semáforo de frescura, uso, acceso (directo/archivo/solo metadatos), territorio DIVIPOLA, calidad.

v_entity_summary_decisor

agregado por entidad con pct_verdes: el indicador de cumplimiento listo para gestión.

Una sola fuente de verdad

panorama web, tablero Power BI y CSVs públicos leen LA MISMA vista — imposible que se desalineen.

Calidad de datos: medida, no declarada

Auditoría columna a columna

17/18 columnas al 100 % de fidelidad contra la fuente Socrata (reportes versionados en eval/reports/).

Clasificación continua

los 2.996 reportes administrativos (Ley 1712) se separan de los datos temáticos automáticamente, en cada corrida del ETL.

Inferencia territorial

códigos DIVIPOLA asignados por IA con confianza registrada (~89 % de cobertura del catálogo).

Guardas anti-basura

metadata placeholder sin diligenciar ({{{name}}}) se descarta en la ingesta; el catálogo no acumula ruido.

Atribución por origen

cada dataset se atribuye al portal donde su entidad publica originalmente — incluso las copias federadas del solapamiento cross-portal.

Evaluación y trazabilidad

Golden sets versionados

eval/golden_queries.yaml y golden_chips.yaml — corridas reproducibles con reportes históricos (16 en eval/reports/).

35 archivos de pruebas

verificador SoQL, validador anti-alucinación, reparación, geo/DIVIPOLA, cosecha, MCP (stdio/SSE), rutas de API.

Evaluación embebida

el verificador corre en producción en cada consulta — la garantía no es una métrica de laboratorio.

Decisiones documentadas

ADRs públicos (017-023): del principio 'la IA razona, el motor verifica' al pivote panorama-decisor.

Telemetría anónima

lo más consultado alimenta la mejora sin datos personales.

Soberanía, seguridad y cumplimiento

Infraestructura del Estado

el servicio corre en infraestructura pública; los datos consultados son públicos por definición.

Sin datos personales

cero registro, cero rastreadores; telemetría agregada y anónima.

Solo lectura

el motor no puede escribir en ninguna fuente; verificación de solo-lectura en la capa 2.

Repo abierto y auditable

código, documentación, pruebas y evaluación públicos — replicable con Docker en cualquier máquina (guía de validación para el jurado).

Accesibilidad

Ley 1618 de 2013 y WCAG 2.1 AA: voz, narración, contraste, escala tipográfica.