

Datos | Vivos

El panorama de los datos abiertos
en Colombia



Jhonatan Rico · Andrea Navarro · Hernán Gutiérrez

Equipo GIT TIC — Agencia Nacional de Infraestructura (ANI)

Concurso Datos al Ecosistema 2026: IA para Colombia — MinTIC

Equipo 93 · Reto de Innovación y Tecnología (Reto 7, id 102) · Nivel Avanzado



datosvivos.co

Nadie tiene el panorama



La entidad

No sabe cuántos datasets tiene publicados ni cuántos están al día.



El sector

Sin vista consolidada de sus entidades adscritas: cero control.



El Gobierno

Los portales federados y el centralizado viven separados: no existe el agregado nacional.



El ciudadano

Necesita saber de búsqueda avanzada de datos o manejo de APIs y SQL para obtener una simple cifra.

El dato público existe — pero nadie puede verlo completo ni usarlo sin conocimientos técnicos

**“Si no conocemos, no podemos medir.
Y si no medimos, no podemos mejorar.”**

El dato bien gobernado es infraestructura — tan estratégica como las vías.

Cuatro ejes, uno por audiencia



Panorama

datosvivos.co

DECISORES NACIONALES

El estado nacional en vivo.
Para ver el estado global en segundos.



Tablero

/tablero · Power BI

CABEZAS DE SECTOR Y ENTIDADES

Detalle por sector, entidad y territorio. Para gestionar que los datos tengan calidad.



Buscador

/buscar · lenguaje natural

CIUDADANÍA

Preguntas en lenguaje natural.
Con cifras verificadas con la fuente. Cero datos inventados



MCP

/mcp · agentes de IA

DESARROLLADORES

El motor como herramientas para Claude, OpenAI y más.

Con accesibilidad en toda la plataforma: **voz, narración y alto contraste (Ley 1618 de 2013).**

El panorama en vivo y actualizado

25.410

datasets en el catálogo

1.421

entidades publicadoras

9 %

actualizados al día

0.3 %

con interacción ciudadana

CÓMO HA CRECIDO EL CATÁLOGO

9 datasets hasta 2015 → **25.410 hoy**

La curva se acelera desde 2023 — la federación de portales territoriales duplicó el catálogo visible en dos años.

SECTORES Y TERRITORIO

Planeación (2.618) y Función Pública (2.169) lideran por sector.

Bogotá (5.110), Cundinamarca (1.372) y Antioquia (1.289) concentran el territorio.

■ 9 % al día ■ 20 % atrasado ■ 71 % con oportunidad de mejora — **DatosVivos hizo visible este indicador por primera vez.**

Cifras en vivo y verificables · 11.039.185 descargas acumuladas · 3.972.184 vistas/mes · corte 26 de julio de 2026

El control de gestión, en dos clics



Semáforo por entidad

Verde dentro de la frecuencia declarada, amarillo hasta 2 veces, rojo más de 2 veces. El porcentaje de cumplimiento queda listo para gestión.



Uso real

Descargas, vistas e interés reciente: muestra qué datasets le importan de verdad a la ciudadanía.



Territorio

Mapa de árbol del alcance de los datos publicados, con cerca del 89 % de cobertura territorial inferida con IA.



Filtros del decisor

Sector, entidad, acceso, calidad (Ley 1712) y territorio: cada gerente arma su propia vista.

La IA está detrás del tablero: la depuración, consolidación y clasificación de calidad se definieron con IA.

“¿Cuántos colegios públicos hay en Boyacá?”

1 Entender

La IA (Claude Haiku, ~1,5 s) convierte la pregunta en chips: TEMA + TIPO (Cuántos, Total, Comparar, Ranking, Tendencia, Mapa) + TERRITORIO. El diccionario ciudadano traduce: “colegios” → “establecimientos educativos” (~130 equivalencias).

2 Encontrar

Embeddings multilingual-e5 sobre ChromaDB recuperan el dataset pertinente entre 25 mil; el filtro territorial recorta a Boyacá vía DIVIPOLA.

3 Generar

Camino principal: SQL determinista por plantillas según el TIPO — la IA no escribe SQL libre, elige entre estructuras verificadas. Modo avanzado: NL→SoQL generativo viendo SOLO columnas curadas reales.

4 Verificar

Código valida columnas, funciones y solo-lectura contra el esquema real ANTES de ejecutar; repara en ciclo acotado o rehúsa. Auto-filtros elegidos SOLO entre ~297.000 valores reales perfilados.

5 Ejecutar

Corre sobre la bodega Parquet local (milisegundos) o sobre el dato vivo si la fuente cambió. Cada cifra se contrasta contra las filas reales.

6 Responder

Respuesta honesta: “1.721 colegios oficiales de 2.184” — cifra + total sin filtrar + dataset fuente + enlace + toggle del SQL ejecutado. Narrativa anti-alucinación: cero cifras inventadas.

0 cifras inventadas 100 % con fuente citada ~1.5 s interpretación NL “Preferimos no responder a responder mal.”

DEMO EN VIVO

Veámoslo funcionando

datosvivos.co — producción, cifras en vivo

1

Panorama

Home: cifras en vivo del catálogo



2

Tablero

/tablero: semáforo por entidad



3

Buscador

“¿Cuántos colegios públicos hay en Boyacá?”



4

Accesible

Modo voz + narración (Ley 1618)

La IA razona, el motor verifica

IA generativa + arquitectura híbrida — pertinente, aplicable e interpretable. Nunca superficial.

CALIDAD DE DATOS (IA)

- ✓ 2.996 reportes administrativos separados (Ley 1712)
- ✓ Curación de columnas: LLM + heurísticas
- ✓ 2.504 vacíos de categoría cerrados (100 %)
- ✓ Vocabulario: de 60+ etiquetas a 25 canónicas
- ✓ Guardas anti-basura ({{...}}) en toda la ingesta

COMPRENSIÓN (IA)

- ✓ Inferencia territorial DIVIPOLA (~89 %)
- ✓ Diccionario ciudadano: ~130 equivalencias
- ✓ Clasificador de intención (6 tipos de respuesta)
- ✓ Embeddings e5 + ChromaDB en ambos caminos
- ✓ Re-ranking semántico del camino estructurado

GENERACIÓN VERIFICADA

- ✓ NL2SQL con verificación de 3 capas (código)
- ✓ Reparación acotada; refusal si no verifica
- ✓ Narrativa anti-alucinación (censura números ajenos)
- ✓ Bodega Parquet: decide local vs dato vivo
- ✓ MCP server para cualquier agente de IA

El mismo dato, cuatro decisiones distintas

El valor no es la herramienta: es que cada actor del ecosistema pasa de no poder ver a poder actuar.

Entidad publicadora

Antes: No sabía cuántos datasets tenía ni cuántos al día. **Ahora:** Ve su rezago en segundos y sabe exactamente qué actualizar.

Gerente de sector

Antes: Cero control sobre sus N entidades adscritas. **Ahora:** Tablero consolidado: compara, prioriza y gestiona el cumplimiento.

MinTIC / política pública

Antes: Los portales federados vivían separados, sin agregado. **Ahora:** Panorama nacional medible para las Hojas de Ruta de Datos Abiertos.

Ciudadanía y prensa

Antes: Consultar un dato exigía saber de APIs y SQL. **Ahora:** Pregunta en sus palabras y recibe cifra verificada con fuente.

Escala: agregar un portal es configuración, no desarrollo — el patrón sirve a cualquier país con Socrata, CKAN o DCAT, y el MCP permite construir encima.

CRISP-ML(Q): qué se hizo en cada fase

1 Entender

El dolor del decisor sin panorama; 6 portales y 3 protocolos (Socrata, CKAN, DCAT) mapeados como fuentes.

2 Preparar

ETL diario con upsert idempotente (0 duplicados), clasificación Ley 1712, curación de columnas e inferencia DIVIPOLA.

3 Modelar

NL2SQL generativo + verificación de 3 capas; embeddings e5 + ChromaDB; clasificador de intención con 6 tipos de respuesta.

4 Evaluar

Golden sets (18/18 chips y 38/38 NL→SoQL, 0 cifras falsas) + ciclo ciudadano: 50 preguntas pre-registradas en 5 ciclos; 48 datasets ejercitados (32 desde bodega, 9 en vivo).

5 Desplegar

Producción en datosvivos.co con Docker
Compose reproducible; imagen horneada; guía de validación para el jurado.

6 Monitorear (Q)

La calidad deriva del catálogo vivo: reindex nocturno, re-clasificación continua y telemetría anónima de lo consultado.

La adaptación central: en vez de entrenar y congelar un modelo, cada consulta vive su propio ciclo — generación (LLM), verificación (código), ejecución.

Fuentes, datasets y variables

9 FUENTES BASE DEL PROCESO 48 DATASETS EN EL PROCESO DE EVALUACIÓN

- ▶ DIVIPOLA (gdx-w37w, DANE): 1.122 municipios + 32 depts — columna vertebral territorial
- ▶ Metadatos DIVIPOLA de entidad (~17.900 datasets) — geolocaliza las 1.421 entidades
- ▶ Catálogo Socrata datos.gov.co (12.164, cosecha diaria)
- ▶ Catálogo DCAT IGAC / Colombia en Mapas (6.699)
- ▶ Catálogos CKAN: Bogotá (4.329) · Cali (1.236) · Valle (106)
- ▶ Catálogo MEDATA Medellín (823)
- ▶ Taxonomía consolidada: 60+ etiquetas → 25 canónicas, 100 % cobertura

VARIABLES EN PRODUCCIÓN

- ▶ **29 variables** en la vista maestra del decisor (identidad, catalogación, semáforo de frescura, uso, señales sociales, calidad, acceso)
- ▶ **14 variables** en la vista por entidad (datasets verdes/amarillos/rojos, consultas, % de cumplimiento)
- ▶ **Curación semántica por columna:** tipo (geo / fecha / métrica / dimensión), subtipo y confianza — habilita el NL2SQL
- ▶ **~297.000 valores filtrables** perfilados: la IA filtra eligiendo entre valores reales, nunca escribiendo SQL libre
- ▶ **48 datasets ejercitados** en el último ciclo de evaluación (detalle en respaldo B7)

No estamos limitados a estos: cualquiera de los 25.410 datasets del catálogo es consultable — índice semántico completo + acceso por lenguaje natural. 10.280 responden además desde copia local en milisegundos.

DETALLE DATASETS

48 datasets ejercitados en el ciclo de evaluación

50 preguntas ciudadanas contra producción (5 ciclos) · 32 respondidas desde la bodega Parquet, 9 en vivo · IDs verificables en datos.gov.co · corte 23 de julio de 2026

26bn-e42j	Créditos otorgados	a3jg-j674	Estudiantes CEFIT	ik3u-sdxz	IPS Capresoca
28vu-5tx7	Formación SENA	a4bc-a9tq	Desastres naturales	j3e8-4hke	Pensionados Fonprecon
2uuh-awp9	Comparendos B/quilla	actn-47cb	Funcionarios Procuraduría	k5bd-cym5	Citas medicina especializada
37hf-6yc2	Contratación Emserchía	aj2e-7jwg	Parque automotor Fusagasugá	k7xp-z2d2	Trámites y OPA
49da-69ff	Viviendas macroproyectos	axk9-g2nh	Tasas de captación	kek9-7v7h	Calidad del aire
52tq-ag6c	Procesos judiciales ANDJE	br9a-gygu	Ejecución de regalías	m8fd-ahd9	Homicidio
5wck-szir	Matrícula ed. superior MEN	c698-wqig	Tarifas energía CHEC	mjt9-2zwc	Población privada de libertad
6jmc-vaxk	Vehículos en accidentes	d3ft-wu2b	Calidad agua río Cauca	mv2e-prx5	Divipole elecciones 2023
72sg-cybi	Lesiones (Policía)	d4t4-daja	Tarifas de acueducto	nb3d-v3n7	Establecimientos y sucursales
7b2d-zmwd	Residuos sólidos	du92-6y56	Flota SITP	qpf2-j35h	Alimentación escolar
7ffd-kpmz	Registro PQRS	fky2-9rg4	Subsidios mejoramiento	s3n2-sqjp	Importadores disp. médicos
7i66-rps2	Estado de vías INVÍAS	fvq4-wwtz	Empleos por entidad	sras-4t5p	Estadísticas educación ETC
7wm8-w5ad	Extranjeros no residentes	h2yr-zfb2	Subsidios de vivienda	u2wk-tfe3	Captaciones por municipio
8u7u-645t	Vacunación Antioquia	hp9r-jxuu	Estaciones IDEAM	u8vy-4dkb	Subsidios vivienda militar
9vha-vh9n	Hurto por modalidades	i7cb-raxc	Medicamentos INVIMA	ucrd-5yjt	Iglesias
d4fr-sbn2	Hurto por modalidades (2)	i9yn-r5bf	Presupuesto Palmira	y399-rzwf	Connacionales registrados

Demo en vivo: emd6-ef7x Establecimientos Educativos (“1.721 colegios oficiales de 2.184 en Boyacá”) · qpq9-e4ne en el ejemplo de cruce del MCP. La solución consulta cualquiera de los 25.410.

Variables: las vistas que alimentan todo

v_dataset_status_decisor — 29 VARIABLES

Identidad: dataset_id, dataset_name, entity_id, entity_name, entity_abbrev

Catalogación: category (25 canónicas), sector, jurisdicción, cobertura geográfica

Semáforo: rows_updated_at, update_frequency, frequency_days, days_since_update, status

Uso: row_count, page_views (total/semana/mes), download_count

Señales sociales: number_of_comments, total_times_rated (NULL = sin interacción, lectura honesta)

Calidad y acceso: quality_flag, es_federado, acceso_datos, socrata_url

v_entity_summary_decisor — 14 VARIABLES

Por entidad: n_datasets (directos/federados), consultas 30d y totales, último acceso, datasets verdes / amarillos / rojos / sin fecha, y pct_verdes — el indicador de cumplimiento listo para gestión.

dataset_columns_curated — HABILITA EL NL2SQL

Cada columna anotada: semantic_type (geo / fecha / métrica / dimensión / exclude), subtipo (código, coordenada, año, conteo, moneda, tasa...) y confianza (high / medium / low).

~297.000 valores filtrables reales perfilados automáticamente desde la bodega (dataset_filter_values): la IA construye filtros eligiendo entre valores que existen — “públicos” → SECTOR = 'OFICIAL' — nunca escribiendo SQL libre.

Una sola fuente de verdad: panorama web, tablero Power BI, CSVs públicos y MCP leen las mismas vistas de PostgreSQL.

Lo que DatosVivos demuestra

La brecha no es de cantidad

Con 25 mil datasets, el problema del dato abierto colombiano es de gobernanza y acceso: los datos existen, pero no se mantienen frescos y consultarlos exigía capacidades técnicas.

Medir cambia la conversación

Al comparar cada dataset contra la frecuencia que su propia entidad declaró, el incumplimiento deja de ser percepción y se vuelve un indicador gestionable por entidad y sector.

La heterogeneidad se absorbe una vez

Consolidar 3 protocolos y metadata desigual con IA (curación, clasificación, inferencia) paga el costo de la federación una sola vez, para todos los usuarios.

Nivel Avanzado, cumplido en producción

Agente de IA sobre grandes volúmenes (25 mil datasets, 6 fuentes), arquitectura híbrida LLM + verificación determinista, y despliegue funcional con actualización diaria: datosvivos.co.

Limitación honesta: el semáforo hereda la calidad de la frecuencia declarada — y eso también es un hallazgo: expone la calidad de la declaración.



datosvivos.co

El panorama de los datos abiertos de Colombia.
En vivo, verificable, para decidir.

Pruébalo ahora



datosvivos.co



Jhonatan Rico · jrico@ani.gov.co · 310 419 6100




Andrea Navarro · inavarro@ani.gov.co




Hernán Gutiérrez · hgutierrez@ani.gov.co

Equipo GIT TIC — Agencia Nacional de Infraestructura (ANI)

Arquitectura: de las fuentes a las cuatro puertas



Motor NL2SQL: generar no basta — hay que verificar



Respaldo determinista (camino estructurado)

Plantillas SoQL por tipo: conteo · suma · comparación · ranking · tendencia · mapa
Los chips del buscador activan este camino — no necesita LLM, el embedding solo re-rankea.

0

cifras inventadas
en producción

100%

con fuente citada
y consulta visible

~1.5s

tiempo de respuesta
API de Claude Haiku

Modelo de datos: una vista curada como fuente única

Toda cifra que se ve en DatosVivos — el panorama web, el tablero Power BI, los CSV públicos y el buscador — se calcula desde la misma vista de PostgreSQL. Al existir una sola fuente de verdad, es imposible que las cuatro puertas se desalineen entre sí.



datasets (42 columnas)

Una fila por dataset del catálogo integrado. La carga usa upsert idempotente por identificador, y la auditoría confirmó cero duplicados de clave.



v_dataset_status_decisor (29 variables)

La vista analítica: identidad del dataset, semáforo de frescura, métricas de uso, tipo de acceso, territorio DIVIPOLA y bandera de calidad.



v_entity_summary_decisor

El agregado por entidad con su porcentaje de datasets al día: el indicador de cumplimiento que un gerente puede gestionar directamente.



Bodega Parquet (10.280 datasets)

Copia local de todos los tabulares viables. El buscador responde desde ella en milisegundos; si la fuente cambió, cae al dato vivo automáticamente.

Calidad de datos: medida, no declarada

La calidad de DatosVivos no es una promesa: cada afirmación tiene una auditoría o un proceso automático detrás, con reportes versionados que el jurado puede replicar.



Auditoría columna a columna

17 de 18 columnas alcanzan 100 % de fidelidad contra la fuente Socrata, con reportes versionados en el repositorio.



Clasificación continua

En cada corrida del ETL, los reportes administrativos (Ley 1712) se separan automáticamente de los datos temáticos.



Catalogación temática al 100 %

2.504 vacíos de categoría se cerraron con clasificación semántica, y el vocabulario se consolidó de 60+ etiquetas a 25 canónicas.



Inferencia territorial

Los códigos DIVIPOLA se asignan con IA registrando el nivel de confianza; la cobertura alcanza cerca del 89 %.



Guardas anti-basura

La metadata de plantilla sin diligenciar se detecta y limpia en todos los campos durante la ingesta, con guarda de recurrencia.



Diccionario ciudadano

~130 equivalencias curadas (“colegios” → “establecimientos educativos”) cierran la brecha entre cómo pregunta la gente y cómo titula el Estado.

Evaluación y trazabilidad

El motor se prueba en dos frentes: uno técnico, con casos de referencia versionados, y uno ciudadano, con preguntas reales cuya respuesta esperada se escribió antes de correrlas. Los patrones que fallan se convierten en mejoras estructurales y el ciclo se repite.



Golden sets versionados

Consultas y chips de referencia en el repositorio, con corridas reproducibles. Últimos resultados: 18/18 y 38/38, cero falsos verificados.



Ciclo ciudadano de 50 preguntas

Cada pregunta tiene respuesta esperada pre-registrada. Las fallas detectadas produjeron mejoras concretas: re-ranking semántico, respuesta de totales y honestidad de lejanía.



36 archivos de pruebas

Cubren el verificador SoQL, el validador anti-alucinación, la reparación, la inferencia territorial, la cosecha, el MCP y las rutas de la API.



Decisiones documentadas (ADRs)

Los registros públicos de decisión (017-024) trazan cada giro técnico, del principio “la IA razona, el motor verifica” al pivote panorama-decisor.

Soberanía, seguridad y cumplimiento

DatosVivos corre en infraestructura del Estado y solo toca datos que ya son públicos. El diseño protege a las personas y hace el sistema auditable de punta a punta.



Infraestructura del Estado

El servicio corre en una VM pública bajo VPN estatal; los datos consultados son públicos por definición.



Sin datos personales

Cero registro y cero rastreadores. La telemetría es agregada y anónima: mide qué se consulta, nunca quién.



Solo lectura

El motor no puede escribir en ninguna fuente; la verificación de solo-lectura es una de las tres capas del pipeline.



Repositorio abierto y auditable

Código, documentación, pruebas y evaluación son públicos, replicables con Docker, con guía de validación para el jurado.



Accesibilidad

Ley 1618 de 2013 y WCAG 2.1 AA: entrada por voz, narración de resultados, alto contraste y escala tipográfica.



Registro oficial

Uso n.º 1074 registrado en herramientas.datos.gov.co (2026-07-13) como aporte formal al ecosistema.